



Elektronski fakultet u Nišu

Augmentacija audio podataka u mašinskom učenju

Student: Danilo Milošević

Profesor: Aleksandar Stanimirović

Sadržaj

1. Uvod	3
2. Osnove audio signala	4
2.1 Digitalni audio signal	4
2.2 Reprezentacije audio signala	5
2.3 Izazovi u radu sa audio podacima	7
3. Osnove augmentacije audio signala	8
4. Augmentacija audio signala u vremenskom domenu	9
4.1 Time Stretching	9
4.2 Pitch Shifting	10
4.3 Dodavanje nasumičnog šuma	12
4.4 Time Shifting	13
4.5 Random Gain	13
5. Augmentacija audio signala u frekventnom domenu	14
5.1 Spectral masking (SpecAugment)	14
5.2 Loudness kontrola	18
5.3 Filtering	19
5.3.1 Low-pass filter	19
5.3.2 High-pass filter	20
5.3.3 Band-pass filter	20
5.3.4 Band-stop filter	21
5.3.5 Comb filter	21
6. Napredne tehnike augmentacije	22
6.1 Simulacija prostorija i reverberacije	22
6.2 MixUp i CutMix	24
6.2.1 MixUp	24
6.2.2 CutMix	24
6.3 Adverserijalne augmentacije	25
6.3.1 Fast Gradient Sign Method	26
6.3.2 Projected Gradient Descent	27
6.4 Naučene augmentacije korišćenjem neuronskih mreža	28
6.4.1 AutoAugment	28
6.4.2 Augmentacija generativnim modelima	29
7. Evaluacija augmentacije	30
7.1 Metrike performansi	30
7.2 Balans između količine augmentacije i performansi	31
7.3 Validacione strategije	32
8. Zaključak	34
9. Literatura	35

1. Uvod

U toku poslednje decenije smo svedoci sve boljih i naprednijih modela veštačke inteligencije, kako kod obrade slika, teksta, videa tako i kod audio podataka. Kao i kod drugih oblasti mašinskog učenja, performanse modela zavise dosta od kvaliteta i količine podataka nad kojima se trenira model. Prikupljanje velike količine kvalitetnih audio podataka (pogotovo anotiranih) je dosta skupo, vremenski zahtevno a u nekim slučajevima i nemoguće. Zbog ovoga primenjujemo augmentaciju podataka.

Augmentacija audio podataka, i uopšte bilo koja vrsta augmentacije podataka, predstavlja skup tehnika kojima se od postojećeg skupa podataka generišu dodatni podaci primenom različitih transformacija. Za razliku od augmentacije slika, koja je danas standardna praksa, augmentacija audio podataka ima dodatne izazove zbog vremenske prirode audio signala, kao i kompleksnosti percepcije zvuka kod ljudi.

Osnovni cilj augmentacije je da se poveća raznovrsnost i veličina trening skupa bez sakupljanja novih podataka, čime se model čini otpornijim na varijacije koje se mogu desiti tokom primene modela (šum npr). Jedan primer je prepoznavanje ljudskog govora. Ukoliko je model treniran na ljudskim glasovima snimljenim u studiju, postoji mogućnost da će performanse modela biti loše u realnim uslovima - na ulici, u kafiću, kod kuće itd.

U ovom radu ćemo prvenstveno obraditi šta je zvuk, kako se može opisati i predstaviti, kao i kakve različite tehnike augmentacije podataka. Razmotrićemo kako jednostavnije tako i kompleksnije transformacije, u različitim domenima, kada i kako treba primeniti date tehnike kao i njihove prednosti i nedostatke. Na kraju ćemo spomenuti kako možemo meriti efikasnost tehnika augmentacije koje će kasnije biti obrađene u praktičnom delu projekta.

2. Osnove audio signala

2.1 Digitalni audio signal

Zvuk je mehanički talas koji se prostire kroz neku sredinu kao rezultat vibracija. Kako bi se zvuk sačuvao na računaru on se zapisuje u digitalnom obliku, gde je predstavljen diskretizovanom verzijom kontinualnog zvučnog talasa. Proces digitalizacije se sastoji od semplovanja (sampling) i kvantizacije.

- **Sampling**

- Proces merenja amplitude zvučnog talasa u regularnim vremenskim intervalima. Frekvencija *sampling*-a određuje koliko puta u sekundi ćemo meriti amplitudu zvučnog signala. Po Nyquist-Shannon-ovoj teoremi semplovanja signala, potrebno je semplovati sa bar duplo manjom frekvencijom od izvorne frekvencije signala. U suprotnom dolazi do *aliasinga*




Figure 1: Semplovanje audio signala

Standardne frekvencije semplovanja (kHz)	Upotreba
8	telefonski govor
44.1	CD kvalitet
48	profesionalni audio
96 ili 192	high-res audio

Table 1: Broj vrednosti amplituda u zavisnosti od broja bitova

- **Kvantizacija**

- Kako su računari digitalni uređaji konačne preciznosti, potrebno je vrednosti amplitude signala mapirati na jednu od 2^n vrednosti, pri čemu n predstavlja broj bitova kojim možemo predstaviti vrednosti amplitude.

Broj bitova	Broj mogućih vrednosti amplitude
8	256
16	65,536 (CD)
24	16,777,216 (profesionalni audio)
32	4,294,967,296 (digitalna obrada signala)

Table 2: Broj vrednosti amplituda u zavisnosti od broja bitova

Audio signal se zatim predstavlja kao diskretan niz vrednosti $x[n]$. Kod mono signala to je jednodimenzionalni niz, dok stereo signal ima dva kanala.

2.2 Reprezentacije audio signala

Audio signali se mogu predstaviti i analizirati na više načina, pri čemu se uglavnom predstavljaju u vremenskom ili u frekventnom domenu.

- **Vremenski domen**

Najjednostavnija reprezentacija audio signala - prikaz amplitude signala kroz vreme.




Figure 2: Prikaz audio signala u vremenskom domenu

Prednosti	Nedostaci
Vremenske informacije su očuvane Nema gubitaka tokom konverzije Lako za razumevanje i prikaz	Nepogodno za analizu frekvencija Zahteva duže sekvence za neuronske mreže

Table 3: Prednosti i nedostaci prikaza audio signala u vremenskom domenu

- **Frekventni domen**

Furijevom transformacijom je moguće izvršiti dekompoziciju audio signala na njegove frekvencije. Analiza signala korišćenjem Furijeove transformacije je pogodna za slučajeve kada frekvencije signala ne variraju vremenom. U realnosti je ovo retkost, s obzirom da ljudski govor i muzika variraju vremenom, tj oni su aperioidični signali.

Zato umesto direktnog vršenja Furijeove transformacije nad signalom, možemo ulazni signal da podelimo na preklapajuće segmente a zatim nad njima vršiti FFT. Podelom audio signala na kratke preklapajuće segmente, a zatim primenom Furijeove transformacije dobijamo STFT - *Short Time Fourier Transform*.

Matematički STFT se može definisati kao

$$\text{STFT}\{x[n]\}(m, \omega) = \sum_{n=-\infty}^{\infty} x[n] w[n - m] e^{-j\omega n} \quad (1)$$

pri čemu je $x[n]$ ulazni signal u trenutku n , dok je w window funkcija i m vreme u okviru kog analiziramo frekvence.




Figure 3: Levo - Proces dobijanja STFT reprezentacije. Desno - STFT reprezentacija. X osa predstavlja vreme, Y osa frekvence a boja intenzitet.

Postoji više window funkcija, ispod je dat primer Hann-ove window funkcije

$$w[n] = \begin{cases} \frac{1}{2} \left(1 - \cos\left(\frac{2\pi n}{N-1}\right) \right), & 0 \leq n < N, \\ 0, & \text{u suprotnom.} \end{cases} \quad (2)$$

STFT reprezentacija međutim ne opisuje najbolje kako ljudsko uho percipira zvuk. Na osnovu istraživanja je zaključeno da ljudi najbolje registruju i razlikuju zvukove u rasponu frekvenci od 500 do 1000Hz, dok teško razlikuju više frekvence npr 1-1.5kHz. Upravo zato je osmišljena mel skala. Mel skala se dobija pretvaranjem linearnog spektrograma u logaritamski na sledeći način

$$m = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$$

pri čemu je m rezultujuća vrednost a f ulazna frekvencija.




Figure 4: Mel spektrogram

Mel spektrogram je pogotovo koristan kod zadataka prepoznavanja govora i muzike.

2.3 Izazovi u radu sa audio podacima

Rad sa audio podacima kod mašinskog učenja donosi nekoliko specifičnih izazova

- **Promenljivo trajanje zvučnih zapisa**

Za razliku od slika koje imaju fiksne dimenzije, audio snimci mogu biti proizvoljnog trajanja. Model mora biti u stanju da procesira signale različite dužine što može da uradi

- Korekcijom dužine snimka, skraćivanjem ili padd-ovanjem signala
- Korišćenjem arhitektura koje primaju ulaze različitih dužina (rekurentne mreže, transformeri)

- **Velika dimenzionalnost**

Audio sa frekvencijom smplovanja od 16kHz ima 16000 vrednosti u sekundi. Za snimak od 10 sekundi, to je 160000 vrednosti. Zbog toga se često koriste kompresovane reprezentacije.

- **Osetljivost na šum**

Zvukovi snimljeni u realnim uslovima često sadrže različite vrste šuma kao što su pozadinski šum, električni šum mikrofona, odjek prostorija, zvukove iz više različitih izvora koji se prepliću (govor više ljudi u isto vreme) itd.

- **Nedostatak label-ovanih podataka**

Kvalitetni, labelovani audio skupovi podataka su relativno mali i skupi. Problem je u tome što je za govor potrebno ručno izvršiti transkripciju sa preciznom vremenskom anotacijom, dok je za muziku potrebna kategorizacija žanrova, instrumenata, takta itd.

- **Varijabilnost govora**

Kod prepoznavanja govora mnogo faktora utiče na audio signal - jezik, akcenat, pol, emotivno stanje, brzina govora, artikulacija, pozadinski šum itd.

Baš zbog ovih izazova je augmentacija audio podataka ključna za treniranje modela koji će imati dobre performanse u realnim uslovima.




Figure 5: Nekoliko vrsta augmentacija audio signala

3. Osnove augmentacije audio signala

Augmentacija podataka je tehnika u mašinskom učenju koja uključuje kreiranje novih trening primera primenom transformacija na postojeće podatke. Metode augmentacije podataka su dizajnirane tako da uvedu dovoljno varijacije u skupu trening podataka tako da održe realističnost i semantički sadržaj ali i poboljšaju sposobnost modela da generalizuje.

Postoji više podela augmentacija audio podataka

1. Po domenu primen
 - **Augmentacije u vremenskom domenu**
Primenjuju se direktno na waveform audio zapisa
 - **Augmentacije u frekventnom domenu**
Primenjuju se na spectrogram audio zapisa
 - **Augmentacije u feature prostoru**
Primenjuju se na ekstrakovnim feature-ima
2. Po složenosti
 - **Jednostavne transformacije**
Dodavanje šuma, promena pitch-a
 - **Kompozitne transformacije**
Nastaju kombinaciju više jednostavnih transformacija
 - **Naučene transformacije**
Transformacije primenom treniranih modela kao što su GAN ili varijacioni auto-encodери
3. Po determinističnosti
 - **Determinističke**
Ista transformacija daje iste rezultate
 - **Stohastičke**
Uvode nasumičnost tokom transformacija

Ciljevi augmentacije podataka su

- **Povećanje veličine trening skupa**
Osnovni cilj je kreiranje većeg i raznovrsnijeg trening skupa bez skupljanja novih podataka. Duboke neuronske mreže, posebno konvolucione mreže i transformeri, zahtevaju velike količine podataka da bi efikasno naučile reprezentacije podataka.
- **Regularizacija i smanjenje overfitting-a**
Uvođenjem varijacije u trening podatke, sprečavamo model da “zapamti” specifične detalje trening skupa. Umesto toga, model mora naučiti robusnije feature-e koji generalizuju na varijacije.
- **Simulacija realnih varijacija**
U produkciji, model će često morati da koristi zvukove koji se razlikuju od trening podataka po kvalitetu snimanja, pozadinskom šumu, akustici prostorije, karakteristikama govornika, itd. Augmentacijom možemo da simuliramo ove varijacije tokom treninga, čineći model otpornijim na realne uslove korišćenja.
- **Balansiranje skupa podataka**
U mnogim scenarijima, dostupni podaci nisu ravnomerno distribuirani kroz klase. Na primer, u skupu podataka za klasifikaciju emocija govornika, normalan govor može biti mnogo češći od ljutitog ili tužnog govora. Selektivnom augmentacijom manje zastupljenih klasa možemo poboljšati balans skupa podataka.

4. Augmentacija audio signala u vremenskom domenu

4.1 Time Stretching

Time stretching je metoda augmentacije audio podataka kojom se produžava ili skraćuje trajanje audio signala bez promene visine tona.

Među jednostavnijim metodama za time stretching je SOLA - *Synchronous Overlap-Add*. Algoritam funkcioniše tako što deli audio na preklapajuće segmente, *frame-ove* i rekonstruiše audio signal sa drugačijim rastojanjem između segmenata. Kod usporenja to znači približavanje segmenata, dok kod produženja se segmenti udaljavaju. Radi na sledećem principu

1. **Deljenje na segmente**

Signal se deli na preklapajuće prozore fiksne veličine, oko 10-100ms, zavisno od toga koliko želimo da promenimo dužinu.

2. **Preklapanje segmenata**

Svaki segment se parcijalno prekriva drugim segmentom (izbor segmenta zavisi od sličnosti između njih, tj biramo slične segmente za preklapanje). Preklapanje se vrši kako bi ublažili prelaz između segmenata




Figure 6: SOLA

Ovaj algoritam ima više varijanti kao što su *WSOLA* i *PSOLA*. U praksi, najbolji je kod jednostavnih, periodičnih audio signala. Nekada daje loše rezultate, kada dođe do lošeg preklapanja segmenata.

Bolja metoda time stretchinga je **Phase vocoder** algoritma koji radi na sledeći način:

1. **Podeli spectrogram na kratke vremenske prozore tj, *frame-ove*** Dobijeni *frame-ovi* se preklapaju delom.
2. **Primeni STFT na *frame-ove***
čime dobijamo amplitude i faze za sve frekvencije u svakom od preklapajućih *frame-ova*
3. **Promena rastojanja *frame-ove***
Kod ubrzavanja *frame-ovi* se približavaju kreirajući overlap. Kod usporavanja će rastojanje biti veće, pa će nastati prazan prostor koji će se popuniti dupliranim *frame-ovima* ili interpolacijom.
4. **Prilagodi fazu svake frekvencije kako bi obezbedio kontinuitet**
Kako bi izbegli приметne skokove u zvuku, potrebno je prilagoditi faze frekvencija kako bi se bolje usaglasili *frame-ovi*.
5. **Primeni inverzni STFT**
Dobijamo izvorni zvuk ali usporen ili ubrzan.




Figure 7: Phase vocoder

Koliko će se promeniti trajanje signala kontroliše se parametrom α .

- $\alpha > 1$ - ubrzan snimak
- $\alpha < 1$ - usporen
- $\alpha = 1$ - bez promene

Time stretching je koristan za

- Simulaciju različitih brzina govora
- Augmentaciju podataka za prepoznavanje govora
- Povećanje invarijantnosti na tempo kod muzike
- Prilagođavanje dužine audio snimaka

Prednosti	Nedostaci
Zadržava visinu i tonalitet Prirodno zvuči u razumnom opsegu faktora Povećava vremensku raznovrsnost podataka	Povećava vremensku raznovrsnost podataka Računski zahtevnije nego jednostavnije augmentacije Može narušiti prirodnost govora ako se pretera

Table 4: Prednosti i nedostaci time shiftinga

4.2 Pitch Shifting

Transformacija komplementarna time stretching-u. Njen cilj je da promeni visinu, tj pitch tona audio signala bez promene njegovog trajanja.

Za pitch shifting možemo koristiti granularnu sintezu ili već pomenuti phase vocoder.

Kod granularne sinteze

1. Delimo signal na sitne intervale

Dok se krećemo kroz audio signal delimo ga na vrlo kratke *grain*-ove, dužine 1-100ms. Grain-ovi se obično preklapaju (overlap) da bi signal bio kontinualan.

2. Menjamo gustinu reprodukcije *grain*-ova

Umesto menjanja trajanja samih *grain*-ova, menjamo **koliko često** ih reprodukujemo. Za viši ton, *grain*-ove reprodukujemo češće nego što su izvađeni iz originalnog signala. Za niži ton, reprodukujemo ih ređe.

3. Korišćenje amplitude envelope

Svaki *grain* dobija amplitude envelope (najčešće Gaussian ili Hanning prozor) koji je nula na krajevima i maksimalan u sredini. Ovo omogućava glatko preklapanje *grain*-ova bez zvučnih artefakata.

4. Overlap-add sinteza

Grain-ovi se sabiru (overlap-add) na izlazu, formirajući kontinualan signal. Veći stepen preklapanja daje gladi, prirodniji zvuk, dok manji overlap može dati “granularnu” teksturu.

5. Održavanje trajanja (opciono)

Ako želimo da zadržimo originalnu dužinu snimka dok menjamo pitch:

- Za pitch up: neki *grain*-ovi se dupliraju ili reprodukuju više puta
- Za pitch down: neki *grain*-ovi se preskakuju/izbacuju

Druga opcija je koristiti phase vocoder kao i kod time stretchinga.

U ovom slučaju

- Primenimo time stretching za faktor α
- Resamplujemo signal sa faktorom $\frac{1}{\alpha}$
- Rezultat ima originalno trajanje ali promenjen pitch




Figure 8: Pitch shifting

Primene pitch shifting-a su sledeće

- Simulacija različitih govornika (muški/ženski glasovi imaju različite fundamentalne frekvencije)
- Augmentacija za muzičku klasifikaciju (transpozicija)
- Kreiranje sintetičkih glasova
- Korekcija tona kod pevačkih aplikacija

Prednosti	Nedostaci
Uvodi varijabilnost u tonalitetu bez menjanja sadržaja Pomoć pri simuliranju različitih govornika Relativno prirodan zvuk u umerenom opsegu	Artifakti pri većim shift-ovima Može promeniti percepciju pola govornika

Table 5: Prednosti i nedostaci pitch shiftinga

4.3 Dodavanje nasumičnog šuma

Dodavanje šuma je jedna od najčešćih i najefektivnijih audio augmentacija. Simulira realne uslove snimanja i čini model robusnijim na različite vrste pozadinskog šuma.

Funkcioniše tako što se čist audio signal $x(t)$ kombinuje sa šumom $n(t)$

$$y(t) = x(t) + \alpha n(t)$$

pri čemu je α intenzitet šuma. Često se koristi i SNR, tj *Signal to Noise Ratio*

$$SNR = 10 * \log_{10}(P_{signal}/P_{noise})$$

gde su P_{signal} i P_{noise} prosečne snage signala i šuma.

Postoji više vrsta šuma, tj više distribucija šuma koje se mogu koristiti u augmentaciji.

- **Beli šum**
 - Šum koji ima podjednaku amplitudu među svim frekvencijama.
 - Zbog ovoga ljudskom uhu zvuči kao šuštanje.
 - Sample-ovi belog šuma su međusobno nezavisni i moguće je generisati ga sample-ovanjem bilo koje nezavisne distribucije (Gaussian, Uniform ...)
- **Roze šum**
 - Šum gde snaga signala opada sa porastom frekvencije.
 - Zato je šum dosta prirodniji za ljudsko uho i češće se javlja u prirodi.
 - Može da se dobije od belog šuma smanjivanjem snage sa porastom frekvencije
- **Brownian šum**
 - Šum gde snaga signala opada proporcionalno kvadratu frekvencije.
 - Još dublji u odnosu na roze šum.
- **Ambijentalni šum**
 - Šum nastao u realnim okruženjima
 - Najrealističniji ali zahteva eksterni skup podataka, teško generisati kao prethodne




Figure 9: Vrste šuma

Prednosti	Nedostaci
Izuzetno efikasna za povećanje robusnosti Simulira realne uslove korišćenja Jednostavna implementacija	Previše šuma može narušiti razumljivost govora Potreban eksterni dataset kod ambijentalnog šuma Može maskirati važne karakteristike signala

Table 6: Prednosti i nedostaci dodavanja šuma

4.4 Time Shifting

Predstavlja jednostavnu transformaciju gde se audio signal pomera unapred ili unazad u vremenu. Na početku ili kraju se zato dodaje tišina ili se cirkularno rotira signal.

Primena time shiftinga - Simulacija različitih početnih tačaka detekcije - Augmentacija za sound event detection - Povećanje robusnosti na poziciju događaja u snimku

Prednosti	Nedostaci
Ekstremno brza transformacija Ne menja akustički sadržaj	Može obrisati važan sadržaj na početku ili kraju Manje korisna kada je temporalna struktura važna

Table 7: Prednosti i nedostaci time shiftinga

4.5 Random Gain

Random Gain je transformacija koja nasumično povećava amplitudu audio signala. Cilj ove transformacije je da simulira različite udaljenosti izvora zvuka od mikrofona ili različite postavke pojačanja tokom snimanja zvuka.

Matematički se definiše kao

$$y[n] = g \cdot x[n]$$

gde se g sempluje iz log-uniformne raspodele, s obzirom da ljudsko uho percipira glasnoću logaritamski.

Pritom je promena u decibelima data kao

$$\Delta dB = 20 \cdot \log_{10}(g)$$

Primena:

- Simulacija različitih udaljenosti od mikrofona
- Normalizacija varijacija u amplitudi između različitih snimaka
- Robusnost na različite postavke pojačanja

Prednosti	Nedostaci
Ekstremno jednostavna i brza Prirodna varijacija koja postoji u realnim podacima	Previše pojačanja dovodi do clippinga Bolja u kombinaciji sa drugim transformacijama

Table 8: Prednosti i nedostaci random gain-a

5. Augmentacija audio signala u frekventnom domenu

Augmentacije u frekvencijskom domenu rade na spektralnim reprezentacijama audio signala kao što su spectrogrami ili mel-spectrogrami. Ove tehnike često omogućavaju precizniju kontrolu nad specifičnim frekvencijskim karakteristikama.

5.1 Spectral masking (SpecAugment)

Spectral masking ili *SpecAugment* je napredna tehnika augmentacije audio podataka, prvi put opisana u radu Google Brain-a tima iz 2019. pod naslovom *SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition*. Ova metoda je pokazala dosta dobre rezultate kod automatskog prepoznavanje ljudskog govora (ASR).

Metoda je bazirana na augmentaciji log mel spektrograma ulaznog audio signala i inspirisana je maskiranjem kod augmentacije u vizuelnom domenu. Tehnika je komputaciono jeftina i primenjuje se direktno na log mel spektrogramu, kao da je spektrogram slika. Zbog ovoga je moguće primeniti spectral masking online, tokom treninga.

SpecAugment se sastoji od tri transformacije nad log mel spektrogramom

- Time warping
- Time masking
- Frequency masking

Time warping

Ukoliko imamo log mel spektrogram sa τ vremenskih koraka, mi ga posmatramo kao sliku gde je vreme horizontalna osa a frekvenca vertikalna osa. Nasumična tačka duž horizontalne linije koja prolazi kroz centar slike u okviru vremena $(W, \tau - W)$ će se *warp*-ovati ulevo ili udesno za distancu w koja se uzima iz uniformne raspodele u opsegu $[0, W]$. Deo signala levo od izabrane tačke se razvlači dok se desni deo skuplja.




Figure 10: SpecAugment - Time warping

Frequency masking

Frequency masking se primenjuje tako da se f uzastopnih mel frequency kanala $[f_0, f_0 + f]$ maskiraju, pri čemu se f bira iz uniformne rapsodele u opsegu $[0, F]$ (F je parametar) a f_0 se bira iz raspona $[0, \nu - f]$, gde je ν broj mel frequency kanala.




Figure 11: SpecAugment - Frequency masking

Time masking

Time masking se primenjuje tako da se t vremenskih koraka $[t_0, t_0 + t]$ maskiraju, pri čemu se t bira iz uniformne rapsodele u opsegu $[0, T]$ (T je parametar) a t_0 se bira iz raspona $[0, \tau - t]$, gde je τ broj vremenskih koraka signala.




Figure 12: SpecAugment - Time masking

Moguće je definisati polise - kombinacije ove 3 metode, sa različitim vrednostima za W , F , i T , kao i primeniti ih na više raspona frekvenci ili više raspona vremenskih koraka. Neki od primera takvih polisa su iz originalnog rada - *LB*, *LD*, *SM* i *SS* koji (izuzev *LB*) primenjuju transformacije nad 2 odvojena raspona frekvencija i 2 raspona vremenskih koraka, sa različitim W , F i T parametrima.




Figure 13: SpecAugment - Policies

Pored klasičnog SpecAugmenta, postoji i druge varijante koje su nastale iz ove metode. Prvi nedostatak kod SpecAugment-a je što se augmentacija podataka vrši samo nad ulaznim podacima neuronske mreže, što propušta priliku za augmentacijom mel spektrograma *hidden state*-a neuronske mreže. Upravo ovo je ideja algoritma *SpecAugment++*.

Pored toga, ova tehnika uvodi i mogućnost maskiranja frekvenci i vremena, ali ne striktno anuliranjem, već i dodeljivanjem druge vrednosti. Konkretno, rad je opisao 3 metoda augmentacije.

- **ZM - Zero Value Masking**
Klasična transformacija, kao i kod *SpecAugmenta*. Deo frekvencija i deo vremenskih koraka se postavlja na 0.
- **MM - Mini-batch based mixture masking**
Kod ove metode se uzimaju mini-batch-evi audio signala nad kojima se primenjuje augmentacija. Tada se hidden state trenutnog *sample*-a $x \in \mathbb{R}^{T \times X}$ menja tako što se uzima hidden state nekog drugog *sample*-a iz istog mini-batcha $y \in \mathbb{R}^{T \times X}$ i u okviru odabranog raspona frekvenci i odabranog raspona vremenskog intervala se računa vrednost mel spektrograma uzorka x kao prosek vrednosti x i y .
- **MM - Mini-batch based mixture masking**
Kod ove metode se uzimaju mini-batch-evi audio signala nad kojima se primenjuje augmentacija. Tada se hidden state trenutnog *sample*-a $x \in \mathbb{R}^{T \times X}$ menja tako što se uzima hidden state nekog drugog *sample*-a iz istog mini-batcha $y \in \mathbb{R}^{T \times X}$ i u okviru odabranog raspona frekvenci i odabranog raspona vremenskog intervala mel spektrogramu uzorka x se dodeljuje vrednost spektrograma y .




Figure 14: SpecAugment++

Najveći nedostatak ove metode je potreba za pažljivi tune-ovanjem parametara augmentacije. Zbog toga je nastala varijacija ovih metoda koja pokušava da automatski odredi najbolje parametre - *Policy-SpecAugment*.

Neka su moguće augmentacije $\{A_1, A_2, A_3\} = \{TimeWarp, FreqMask, TimeMask\}$ i neka je u epohi j , prosečan validation loss primenom samo i -te augmentacije $\mathcal{L}_i^j$.

Zatim se ti validation loss-ovi koriste kako bi se dobio vektor verovatnoća

$$P_i^{(j)} = \frac{\mathcal{L}_i^{(j)}}{\sum_{k=1}^3 \mathcal{L}_k^{(j)}} \quad (3)$$

Ovako dobijenim vektorima verovatnoće moguće je dalje usmeriti augmentaciju tako da se primenjuju one transformacije koje će poboljšati performanse.

Prednosti	Nedostaci
Izuzetno efikasna za ASR zadatke Može maskirati kritične informacije Brza jer radi direktno na spektrogramu	Može maskirati kritične informacije Potrebno pažljivo tune-ovanje parametara za specifične zadatke

Table 9: Prednosti i nedostaci SpecAugment-a

5.2 Loudness kontrola

Loudness kontrola je metoda augmentacije podataka koja se primenjuje u frekventnom domenu i omogućava manipulaciju percipirane glasnoće zvuka, za razliku od random gain-a.

Kod random gain-a smo nasumično pojačavali amplitude nekim faktorom g , smplovanim korišćenjem uniformne raspodele. Međutim ova metoda ne uzima u obzir percepciju ljudskog uha. Ljudsko uho je najosetljivije na frekvence u opsegu od 2kHz do 5kHz (sa vrhom oko 3.5-4kHz) i poklapa se sa frekvencom rezonance kanala ljudskog uha.




Figure 15: Osetljivost ljudskog uha na različite frekvencije

Kontrola glasnoće, odnosno *loudness control* uzima u obzir osetljivost ljudskog uha i skalira spektar prema perceptualnim krivama.

Primenjuje se na spektrogramu zvuka:

$$S' [f, t] = S [f, t] \cdot L (f) \cdot g$$

pri čemu je

- $L (f)$ frekventijski zavisna težina bazira na perceptualnim modelima i data je kao funkcija frekvence. Ona određuje koliko će se skalirati svaka frekvenca.
- g je skalar kojim se određuje koliko primeniti kontrolu glasnoće

Najčešće se za $L (f)$ koristi *A-weighting* koja je data kao

$$R_A(f) = \frac{12194^2 f^4}{(f^2 + 20.6^2) \sqrt{(f^2 + 107.7^2) (f^2 + 737.9^2) (f^2 + 12194^2)}} \quad (1)$$

$$A(f) = 20 \log_{10} (R_A(f)) - 20 \log_{10} (R_A(1000)) \quad (2)$$

Ova metoda se primenjuje za

- Normalizaciju glasnoće između različitih snimaka
- Simulaciju različitih slušnih uslova
- Povećanje konzistentnosti trening podataka




Figure 16: A-weighting kriva

Prednosti	Nedostaci
Bolje odgovara ljudskoj percepciji Korisna za normalizaciju dataset-a	Kompleksnija implementacija Sporije nego random gain

Table 10: Prednosti i nedostaci loudness kontrole

5.3 Filtering

Filtriranje je metoda augmentacije audio podataka kao i tehnika obrade signala gde se određene frekvencije (audio ili slike) zadržavaju dok se određene frekvencije izbacuju ili atenuiraju, odnosno umanjuju određenim faktorom.

Frekvencija nakon koje kreće atenuacija ili odbacivanje se zove **cutoff** frekvencija.

Postoji više različitih vrsta filtera, zavisno od toga koje frekvencije filtriraju

5.3.1 Low-pass filter

Low-pass filter atenuira odnosno oslabljuje frekvencije iznad datog cutoff-a. Koristi se prvenstveno za redukciju šuma kako u audio snimcima tako i u slikama, s obzirom da je šum najčešće signal visoke frekvence kao što je pozadinski ili električni šum kod mikrofona.




Figure 17: Low-pass filter

5.3.2 High-pass filter

High-pass filter predstavlja komplement low-pass filtera, odnosno atenuira frekvencije ispod zadatog cutoff frekvencije. Najčešće se koristi za redukciju šuma niskih frekvencija (kao što je šum nastao dodirivanjem mikrofona, pozadinskog šuma nastalog klima uređajima itd.) kao i za poboljšanje jasnoće ljudskog govora.




Figure 18: High-pass filter

5.3.3 Band-pass filter

Nastaje kombinacijom low-pass i high-pass filtera, odnosno atenuira frekvencije ispod zadate frekvencije f_L i iznad frekvencije f_H . Kod audio augmentacije koristi se za uklanjanje istovremeno nisko frekventnog i visoko frekventnog šuma.




Figure 19: Band-pass filter

5.3.4 Band-stop filter

Takođe poznat kao i band-reject filter, predstavlja komplement band-pass filter-a. Ovde se filtriraju frekvencije u opsegu $[f_L, f_H]$. Primer primene kod audio obrade je uklanjanje mikrofonijske kod muzike.




Figure 20: Band-stop filter

5.3.5 Comb filter

Nastaje atenuacijom više različitih raspona frekvencija

$$[f_{L_1}, f_{H_1}], [f_{L_2}, f_{H_2}], [f_{L_3}, f_{H_3}], \dots [f_{L_n}, f_{H_n}]$$

zbog čega signal dobija izgled češlja. U praksi se comb filter implementira dodavanjem signala koji je pomeren vremenski originalnom signalu, tj formulom

$$y[n] = x[n] + \alpha x[n - K]$$

gde je α parametar koji kontroliše koliko se dodaje vremenski pomeren signal a K predstavlja zakašnjenje, tj *delay*.




Figure 21: Comb filter

Prednosti	Nedostaci
Precizna kontrola frekvencijskog sadržaja Simulacija različitih prenosnih medijuma	Može poremetiti faze Može ukloniti važne informacije

Table 11: Prednosti i nedostaci filtering-a

6. Napredne tehnike augmentacije

Metode koje smo do sada obradili predstavljaju relativno jednostavne izmene audio signala u vremenskom ili frekventnom domenu. U ovoj oblasti ćemo sagledati kompleksnije tehnike augmentacije podataka koje koriste različite metode za augmentaciju kao što su fizičke simulacije karakteristika prostorija, augmentaciju pomoću neuronskih mreža i interpolaciju više različitih snimaka.

6.1 Simulacija prostorija i reverberacije

Reverbacija, odnosno odjek, je akustički fenomen koji nastaje kao posledica refleksije zvuka od površina u prostoriji i zato zavisi od geometrije prostorije i predmeta u njoj. Zbog ovoga je simuliranje reverbacija veoma korisna metoda augmentacije audio podataka, s obzirom da dodaje raznovrsnost i realizam među audio podacima.

Kada se zvuk emituje u prostoriji, slušalac čuje taj zvuk na više načina

- **Direktno od izvora**

Zvuk koji stiže od izvora do slušaoca najkraćim, direktnim putem. S obzirom da se zvuk emituje podjednako u svim pravcima, samo mali deo energije zvučnog talasa dolazi do slušaoca, dok većina predstavlja indirektni zvuk koji se dalje deli na kategorije ispod.

- **Rane refleksije**

Ostatak zvuka koji ne dolazi do slušaoca direktno od izvora se odbija od zidova, prozora, kao i svih predmeta u prostoriji. Zvuk koji nakon odbijanja dolazi do slušaoca u roku od 0-50ms predstavlja ranu refleksiju. Rane refleksije su veoma bitne za razumevanje ljudskog govora. Ukoliko se izvor i slušalac nalaze u otvorenoj ravnoj prostoriji (ravnicu, pustinja...) jedini zvuk koji dolazi do slušaoca je direktan zvuk, pa će se zvuk slabo čuti već posle nekoliko metara.

- **Kasne refleksije**

Kasne refleksije su jasno odvojene od originalnog signala i lako primetne ljudskom uhu kao zakašnjenja. Primer ovoga je eho. Kasne refleksije nastaju odbijanjem zvuka i dolaska do slušaoca nakon 50ms do 250ms.

- **Reverberacija**

Zvuk koji nastaje odbijanjem originalnog signala od zidova i predmeta u prostoriji i dolazi do slušaoca nakon 250ms i više se ne prepoznaje kao zakasneli originalni zvuk, već kao relativno tih zvuk koji dolazi iz svih smerova. Reverberacija može da traje oko 2-5s nakon čega zvuk potpuno nestaje.

Za predstavljanje reverbacije u nekom prostoru koristi se **Room Impulse Response** koji predstavlja funkciju koja opisuje kako se u okviru prostorije prostiru direktni zvukovi, rane i kasne refleksije kao i reverberacija.




Figure 22: Izvori zvuka

Kako bi se dobio reverberiran signal primenjuje se konvolucija izvornog zvuka i *RIRa*.

$$y(t) = x(t) \otimes h(t)$$

Bitan parametar reverbacije je **RT60**, odnosno vreme u sekundama potrebno da zvuk oslabi za $60dB$ nakon što izvor prestane da emituje zvuk, time opisujući reverbaciju prostorije. Za standardne prostorije (sobe u kući) *RT60* je 0.2-0.4 sekunde, dok je na primer kod katedrala oko 5-10s. Ovo vreme zavisi od veličine i oblika prostorije kao i od materijala zidova - neki materijali više ili manje apsorbuju zvuk.

Postoji nekoliko metoda primene reverbacije

1. Konvolucija sa snimljenim RIR-om

Predstavlja najrealističniji pristup. Prvo se snimi room impulse response u više različitim prostorija a zatim se primenjuje konvolucija RIR-a i originalnog signala. Postoje više javno dostupnih RIR dataset-ova kao što su *MIT Acoustical Reverberation Scene Statistics Survey*, *OpenAIR*, *BIRD* i mnogi drugi.

2. Algoritamska reverbacija

Umesto snimanja RIR-a za različite prostorije moguće je algoritamski simulirati reverbaciju različitih prostorija. Neki od najpoznatijih algoritama su *Schroeder-ov reverb*, *Freeverb* (baziran na *Schroeder-ovom reverbu*), *Dattorro reverb* i mnogi drugi.

Schroeder-ov reverb radi na osnovu više paralelnih comb filtera i više serijskih allpass filtera koji puštaju sve frekvence ali menjaju faze signala. Izlazi paralelnih comb filter-a se sekvencijalno propuštaju kroz allpass filtere i na kraju se dobija signal sa reverberacijom.




Figure 23: *Schroeder* reverbacija

3. Parametarski pristup

Koristi parametre kao što su pre-delay, decay time, diffusion da generiše reverbaciju bez fizičke simulacije.

Prednosti	Nedostaci
Visoko realistična augmentacija Poboljšava robusnost na različite akustičke uslove	Računski skupa Računski skuplja

Table 12: Prednosti i nedostaci simulacije reverbacije

6.2 MixUp i CutMix

MixUp i CutMix su metode augmentacije koje kombinuju dva podatka iz trening skupa kako bi se dobile nove instance. Prvenstveno su razvijene za augmentaciju podataka u domenu računarskog vida ali su kasnije prilagođene za augmentaciju audio podataka.

6.2.1 MixUp

MixUp funkcioniše tako što na osnovu dva audio signala (x_1, y_1) i (x_2, y_2) formira novi primer (x_{mix}, y_{mix}) linearnom kombinacijom prva dva signala na sledeći način

$$x_{mix} = \lambda \cdot x_1 + (1 - \lambda) \cdot x_2 \quad (1)$$

$$y_{mix} = \lambda \cdot y_1 + (1 - \lambda) \cdot y_2 \quad (2)$$

Na slici ispod možemo da vidimo efekat MixUp augmentacije na mel spektrogramima dva uzorka




Figure 24: MixUp

6.2.2 CutMix

CutMix takođe formira na osnovu dva audio signala treći kombinovanjem, ali nema interpolacije, već se deo prvog signala menja delom drugog signala.

Postoje više vrste CutMix-a, zavisno od toga na kojim se primerima u trening skupu primenjuje i nad kojom reprezentacijom audio signala.

- **Between-Class**

Meša signale instanci iz različitih klasa.

- **Within-Class**

Meša primere isključivo iz iste klase.

- **SpecMix**

Primenjuje mixup na mel spektrogramu umesto na waveform.

- **PatchMix**

Primenjuje mixup tako što menja nasumične patch-eve spektrograma između dve izabrane instance.




Figure 25: SpecMix

Prednosti	Nedostaci
Jednostavna augmentacija za razumevanje i implementaciju Služi kao i regularizacija	Ne čini model robustnijim na kompleksnije adverserijalne primere Računski skupo, s obzirom da vršimo trening dva puta

Table 13: Prednosti i nedostaci MixUp-a i CutMix-a

6.3 Adverserijalne augmentacije

Kod ove metode augmentacije se u trening skupu dodaju nove instance koje su generisane izmenom originalne instance tako da se obmane model.

Na slici ispod možemo videti primer adverserijalne perturbacije na primeru slika kao i audio podataka. Dodavanjem specifično dizajniranog šuma slici ili audio zapisu model generiše znatno drugačije izlaze.




Figure 26: Primer adverserijalnih perturbacija

Međutim ručno definisati adverserijalne perturbacije za svaki trening primer je nepraktično, pogotovo kod većih skupova podataka, tako da je potrebno generisati algoritamske perturbacije. Razmotrićemo ispod dve tehnike.

6.3.1 Fast Gradient Sign Method

Fast Gradient Sign Method ili *FGSM* je primer white-box napada, što znači da zahteva znanje arhitekture i parametara modela. Ideja je da se originalnom podatku doda mala količina šuma baziranog na gradientu loss funkcije po ulaznom vektoru.

Princip rada ovakve augmentacije je

1. Trening modela

S obzirom da je potrebno imati definisanu arhitekturu i parametre modela, potrebno je kreirati model i trenirati ga nad datim skupom podataka.

2. Računanje gradijenta

Ako imamo x kao ulazni podatak, y klasu i $J(\theta, x, y)$ kao loss funkciju pri čemu θ predstavlja parametre modela, onda se gradijent dobija kao

$$\nabla_x J(\theta, x, y) = \frac{\partial J}{\partial x}$$

3. Računanje perturbacije

Na osnovu dobijenog gradijenta možemo sračunati perturbaciju δ na sledeći način

$$\delta = \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$$

pri čemu ϵ predstavlja magnitudu perturbacije.

4. Generisanje adverserijalnih primera

Za svaku od instanci x u originalnom trening skupu možemo odrediti gradijent i perturbaciju. Tada se dobija adverserijalni primer na sledeći način

$$x' = x + \delta$$

5. Retreniranje modela

Sa tako dobijenim skupom podataka koji sačinjavaju originalne instance i adverserijalni primeri možemo ponovo trenirati model koji će biti otporniji na adverserijalne napade.




Figure 27: Fast Gradient Sign Method

6.3.2 Projected Gradient Descent

Projected Gradient Descent ili *PGD* predstavlja iterativni algoritam za dobijanje adverserijalnih primera i baziran je na sličnim idejama koje imamo kod *FGSDa*, tj koristi računanje gradijenta i perturbacije. Razlikuje se od *FGSDa* po tome što dodaje perturbaciju iterativno, u više koraka, i to na sledeći način.

1. Inicijalni uslov i ulazni parametri

Na početku biramo broj iteracija T , maksimalnu magnitudu perturbacije ϵ i veličinu koraka α . U ovom koraku postavljamo incijalno

$$x'_0 = x_0 + noise$$

Šum, tj *noise* se sample-uje iz uniformne raspodele u dozvoljenoj ϵ -lopti.

2. Iterativni postupak

U svakom koraku $t = 0, 1, \dots, T - 1$ računamo gradijent loss funkcije za ulaz x'_t , a zatim uzimamo njen znak, slično kao kod *FGSDa*. Zatim se vrši ažuriranje vrednosti na sledeći način

$$x'_{t+1} = \Pi(x'_t + \alpha \cdot \text{sign}(\nabla_x J(\theta, x'_t, y)))$$

pri čemu je Π **projekciona** funkcija koja ograničava vrednosti sledećeg koraka na validne vrednosti za dati tip podataka - npr kod audio augmentacije ograničava amplitudu signala kako ne bi previše odudarala od početne vrednosti.

3. Retreniranje modela

Kao i kod *FGSDa*, s obzirom da tokom generisanja primera koristimo težine modela, potrebno je izvršiti retreniranje modela korišćenjem augmentovanog skupa podataka.

U odnosu na *FGSD* ova metoda je dosta sporija, s obzirom da se vrši u više iteracija ali zato proizvodi robustnije adverserijalne primere.

Prednosti	Nedostaci
Jednostavna implementacija	Potrebno tuniranje ϵ parametra
Postiže se robustnost na adverserijalne napade	Računski skupo
Služi kao i regularizacija	Može usporiti konvergenciju

Table 14: Prednosti i nedostaci adverserijalne augmentacije




Figure 28: Projected Gradient descent

6.4 Naučene augmentacije korišćenjem neuronskih mreža

Problem kod svih prethodnih metoda augmentacije je bila potreba za ručnim definisanjem pravila kako augmentisati podatke. Umesto ručne augmentacije, moguće je naučiti modele da generišu nove podatke (generativni modeli kao što su GAN-ovi, autoencodери itd.) ili definisanjem mogućih augmentacija nakon čega model uči kako kombinovati augmentacije da bi model ostvario bolje rezultate preko reinforcement learning-a

6.4.1 AutoAugment

Opisan u Google-ovom radu iz 2019 godine, predstavlja reinforcement learning metodu koja uči kako kombinovati augmentacije tako da model ostvari bolje performanse. Iako prvenstveno razvijan za slike, moguće je primeniti i na audio podacima.

Princip rada je sledeći

1. Inicijalizacija

U prvom koraku se inicijalizuje, odnosno definiše *search space* augmentacija što predstavlja sve moguće augmentacije koje agent može primeniti nad podacima kao i njihove parametre. Cilj agenta je pronaći u tom prostoru augmentacija najbolje kombinacije.

2. Predlaganje politike

U sledećem koraku reinforcement learning agent predlaže *augmentation policy*, tj politiku augmentacije, što predstavlja kombinaciju augmentacija i parametara.

3. Trening modela

Koristeći predloženu politiku augmentacije, model se trenira sa augmentisanim skupom podataka i mere se performanse tako dobijenog modela.

4. Ažuriranje agenta

Mere se performanse modela treniranog sa primenjenom politikom i rezultati se koriste kao nagrade (*reward*) za reinforcement learning agenta. Na ovaj način, kroz iteracije, agent uči koje augmentacije najbolje utiču na performanse modela-




Figure 29: AutoAugment kod slika

6.4.2 Augmentacija generativnim modelima

Generativnim modelima je moguće generisati nove instance podataka nad kojima se kasnije može model trenirati. Postoji više tipova generativnih modela, međutim ovde ćemo razmotriti način rada *GAN*-ova odnosno generativnih adverserijalnih mreža i njihovu upotrebu za augmentaciju podataka.

Generativne adverserijalne mreže se sastoje od dve komponente - **generatora** i **diskriminatora** i rade na sledećem principu

1. **Generator generiše *fake* podatke**

Generator dobija na ulaz-u šum koji zatim pretvara u izlaz koji treba biti što uverljiviji.

2. **Diskriminator predviđa da li je ulaz lažan ili pravi podatak**

Diskriminator se trenira da prepozna da li je podatak pravi ili lažan, tako što se na ulaz dovodi podatak, on generiše predviđanje a zatim se težine koriguju u zavisnosti da li je predviđanje tačno.

3. **Generator se ažurira**

Na osnovu rezultata diskriminatora se nagrađuje ili kažnjava generator. Ako je diskriminator prepoznao lažan podatak, generator se kažnjava a suprotnom nagrađuje i težine generatorske mreže se koriguju.

4. **Kraj treninga**

Trening se završava kada tačnost predviđanja diskriminatora dođe do 50%, tj kada diskriminator više ne može sa sigurnošću da razlikuje prave i lažne podatke.

Kod augmentacije audio podataka možemo koristiti *GAN*-ove za generisanje novih primera i to pomoću

- **WaveGan** koji služi za generisanje zvuka u wave formatu
- **SpecGAN** koji služi za generisanje spektrograma

Prednost ove metode je što može lako generisati nove primere pa time pomoći kada nemamo puno primera ili kod nebalansiranih klasa, međutim treniranje *GAN*-ova je dugo i može biti teško podesiti parametre kako bi dobili dobre rezultate.




Figure 30: Princip rada *GAN*a

Prednosti	Nedostaci
Može otkriti nove, efikasne augmentacije Automatizuje augmentaciju Visoko realistični primeri kod <i>GAN</i> a	Ekstremno računski skupo Treniranje <i>GAN</i> a može biti dugo

Table 15: Prednosti i nedostaci naučenih augmentacija

7. Evaluacija augmentacije

U ovom poglavlju ćemo razmotriti različite metrike i načine evaluacije augmentacija koje smo obradili u prethodnim poglavljima, što će služiti kao osnova praktičnog dela projekta.

7.1 Metrike performansi

Kao i kod ostalih domena, za merenje performansi kod klasifikacionije audio podataka možemo koristiti standardne metrike, kao što su

- **Konfuzione matrice** koje upoređuju predviđene i prave klase, što se kod binarne klasifikacije svodi na 4 vrednosti - true positive, true negative, false positive i false negative.
- **Accuracy** koji se računa kao

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision** koji se računa kao

$$Precision = \frac{TP}{TP + FP}$$

- **Recall** koji se računa kao

$$Recall = \frac{TP}{TP + FN}$$

- **F1-Score** koji se dobija na osnovu precision i recall-a

$$F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}$$

F1 je pogotovo korisna metrika kod neujednačenih skupova i može se računati na dva načina

– *Macro F1*

Računa se kao prosek F1 za svaku od klasa, gde se svaka klasa tretira podjednako

– *Micro F1*

Računa se globalno, preko svih instanci, time favorizujući većinske klase

- **Mathews korelacioni koeficijent** računa se na sledeći način

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Pored standardnih metrika postoje i metrike specifične kod audio problema

- **Word Error Rate**

Koristi se kod *ASR - Automatic Speech Recognition* i računa se na sledeći način

$$WER = \frac{S + D + I}{N}$$

pri čemu je S broj pogrešno prepoznatih reči, D broj reči koje fale, I broj dodatih reči koje nisu u snimku dok je N ukupan broj reči u snimku.

- **Character Error Rate**

Računa se isto kao WER ali na nivou karaktera. Ova metrika je korisna kod jezika sa složenim karakterima kao što su japanski, arapski i drugi.

- **Event-Based i Segment-Based F1**

F1 metrike karakteristične za audio domen. *Event-Based F1* se računa na nivou event-a, događaja u audio zapisu, dok *Segment-Based F1* deli snimak na kratke segmente (oko 1s) i računa F1 na svakom segmentu.

7.2 Balans između količine augmentacije i performansi

Veliki problem kod augmentacije podataka jeste koliko augmentacije primeniti.

Premalo augmentacije može izazvati

- Overfitting modela na trening podacima
- Loša generalizacija na test podacima

dok **previše** augmentacije može izazvati

- Gubitak važnih informacija
- Podaci mogu postati nerealistični
- Sporija konvergencija

Postoji nekoliko načina za pronalaženje balansa u augmentaciji

1. Ablation study

Ovom metodom se sistematski testira efekat svake augmentacije pojedinačno kao i u kombinaciji. Prvi korak je izmeriti performanse bez ikakvih augmentacija, odnosno *baseline* a zatim primeniti svaku augmentaciju odvojeno kao i njihove kombinacije. Na osnovu skupljenih metrika (npr preciznost) možemo zaključiti koja je najbolja kombinacija metrika

2. Parameter sweep

Može se koristiti i u kombinaciji sa *ablation study*. Cilj je varirati intenzitet augmentacija dok ne zaključimo najbolje parametre za augmentacije.

3. Nadgledati krive metrika

Kod ove metode potrebno je nadgledati krive trening i validacionih metrika. Ukoliko je gap veliki potrebno je više augmentacije, ukoliko su metrike loše onda je potrebno smanjiti augmentacije ili promeniti model, dok ako je konvergencija spora moguće je da imamo previše augmentacije.

4. Progresivna augmentacija

Umesto primenjivanja pune augmentacije vršimo postepeno povećanje augmentacija tokom treninga.

5. Validacija u različitim uslovima

Dobra ideja je evaluirati model na više različitih test setova - na čistom setu, test setu sa dodatim šumom, test setu sa dodatom reverbacijom itd.

Generalni saveti tokom augmentacija koje ćemo primeniti i tokom evaluacije u praktičnom delu rada su

- Početi sa manjom augmentacijom a zatim dodavati postepeno
- Augmentaciju vršiti na 40-70% trening primera, ne na svim
- Validaciju i testiranje vršiti bez primenjenih augmentacija

7.3 Validacione strategije

Nakon što smo objasnili metrike i kako balansirati augmentaciju, potrebno je razmotriti kako validirati rezultate.

• Cross-Validation i Stratified K-fold

Standardne validacione strategije koje se mogu koristiti i u drugim domenima, ne samo kod zvuka. Strategija funkcioniše tako što se skup podataka deli na k delova, zatim se k puta ponavlja proces gde se jedan deo ostavlja za validaciju dok se model trenira nad ostalim komponentama. *Stratified* verzija radi na istom principu ali se vodi računa da se zadrži ista raspodela među klasama u svakom od k delova.

• Speaker-independent splits

Ova metoda je kritična kod generalno svih zadataka gde se prepoznaje govornik ili govor. Ideja ove metode je da se trening, validacioni i test organizuju tako da se govornici u test setu nikada

ne uključuje u trening set. Cilj je postizanje robustnosti modela za prepoznavanje govora čak i za govornike koje model nije čuo prethodno.

- **Temporal split**

Koristi se kod time-series ili streaming aplikacija. Ideja je da test validation i test set budu odvojeni u vremenu, tj train set sadrži uzorak snimka u intervalu $[0, t_1)$, validation $[t_1, t_2)$ i test u intervalu $[t_2, t_3]$.

- **Domain-based split**

Kod ove metode se test i train set razlikuju po domenu, tj train set sadrži podatke iz source domena (npr snimci glasova snimljeni u studiju) a test set sadrži podatke iz target domena (npr glasovi snimljeni u realnom svetu, u imperfektnim uslovima).

- **Augmentation-aware validacija**

Ukoliko se primenjuje augmentacija uvek treba koristiti ovu metodu, potencijalno sa drugim metodama. Ovom metodom se validacija i testiranje vrše na ne-augmentovanim podacima, kako ne bi dobili lažno dobre rezultate.




Figure 31: Cross-Validation

8. Zaključak

Kroz ovaj rad smo videli da je augmentacija audio podataka postala praktično nezaobilazan korak u modernom mašinskom učenju. Glavna prednost ovih tehnika je što nam omogućavaju da “izvučemo maksimum” iz postojećih podataka, praveći modele koji su otporniji na buku, promenu mikrofona ili različite prostore u kojima se zvuk snima.

Ipak, najvažnija lekcija je da ne postoji jedno univerzalno pravilo koje radi za sve. Ono što pomaže sistemu za prepoznavanje govora ne mora nužno biti dobro za klasifikaciju muzike ili emocija. Ključ je u balansu – ako preteramo sa transformacijama, možemo toliko izmeniti zvuk da on izgubi svoj smisao, što na kraju zbuni model umesto da ga nauči nečem novom. Zato je najbolje kombinovati više različitih, jednostavnijih metoda i stalno proveravati rezultate na realnim podacima.

Danas nam dostupni softverski alati značajno olakšavaju implementaciju ovih metoda, ali je i dalje presudno razumeti samu prirodu zvuka i specifičnosti zadatka na kojem radimo. Augmentacija je moćan alat koji nam pomaže da nadomestimo manjak podataka, ali ona nikada ne može u potpunosti zameniti kvalitetno prikupljen i tačno označen set snimaka.

U budućnosti možemo očekivati još pametnije sisteme koji će sami birati najbolje transformacije ili čak koristiti veštačku inteligenciju za kreiranje potpuno novih, realističnih primera. Sve u svemu, uz pametno eksperimentisanje, augmentacija ostaje jedan od najboljih načina da naši audio modeli postanu pouzdaniji i spremniji za primenu u stvarnom svetu.

9. Literatura

1. Car Audio – *Pitch Shifting Explained*
<https://carpaudio.com/blogs/knowledge-base/pitch-shifting>
2. Surina – *Time and Pitch Scaling*
<https://www.surina.net/article/time-and-pitch-scaling.html>
3. CMTEXT – *Phase Vocoder*
https://cmtext.com/synthesis/chapter4_pv.php
4. Neekhara, P., Hussain, S., Dubnov, S., Koushanfar, F. – *Adversarial Attacks on Automatic Speech Recognition Systems via Psychoacoustic Hiding*
<https://arxiv.org/pdf/1904.08779>
5. Schönherr, L., et al. – *Adversarial Attacks Against Automatic Speech Recognition Systems via Psychoacoustic Hiding*
<https://arxiv.org/pdf/2103.16858>
6. Emergent Mind – *Policy SpecAugment*
<https://www.emergentmind.com/topics/policy-specaugment>
7. Wikipedia – *A-weighting*
<https://en.wikipedia.org/wiki/A-weighting>
8. Wikipedia – *Low-pass filter*
https://en.wikipedia.org/wiki/Low-pass_filter
9. Wikipedia – *Filter (signal processing)*
[https://en.wikipedia.org/wiki/Filter_\(signal_processing\)](https://en.wikipedia.org/wiki/Filter_(signal_processing))
10. Aural Exchange – *Understanding Sound Reflections*
<https://www.auralexchange.com/knowledgebase/understanding-sound-reflections/>
11. Schroeder, M. – *Natural Sounding Artificial Reverberation*
https://hajim.rochester.edu/ece/sites/zduan/teaching/ece472/reading/Schroeder_1962.pdf
12. ResearchGate – *An Illustration of Machine Learning Adversarial Examples*
https://www.researchgate.net/figure/An-illustration-of-machine-learning-adversarial-examples-Studies-have-shown-that-by_fig1_324055823
13. ShadeCoder – *Projected Gradient Descent Attack: A Comprehensive Guide for 2025*
<https://www.shadecoder.com/topics/projected-gradient-descent-attack-a-comprehensive-guide-for-2025>
14. Medium – *Unveiling the Power of Projected Gradient Descent in Adversarial Attacks*
<https://medium.com/@zachariaharungeorge/unveiling-the-power-of-projected-gradient-descent-in-adversarial-attacks-2f92509dde3c>
15. Madry, A., et al. – *Towards Deep Learning Models Resistant to Adversarial Attacks*
<https://arxiv.org/abs/1904.09135>
16. Carmon, Y., et al. – *Unlabeled Data Improves Adversarial Robustness*
<https://arxiv.org/abs/2104.00560>