



Elektronski fakultet u Nišu

Augmentacija audio podataka u mašinskom učenju

Student: Danilo Milošević

Profesor: Aleksandar Stanimirović

Sadržaj

1. Uvod	3
2. Osnove audio signala	4
2.1 Digitalni audio signal	4
2.2 Reprezentacije audio signala	5
2.3 Izazovi u radu sa audio podacima	7
3. Osnove augmentacije audio signala	8
4. Augmentacija audio signala u vremenskom domenu	9
4.1 Time Stretching	9
4.2 Pitch Shifting	9
4.3 Dodavanje nasumičnog šuma	9
4.4 Time Shifting	9
4.5 Random Gain	9
5. Augmentacija audio signala u frekventnom domenu	10
6. Napredne tehnike augmentacije	11
7. Evaluacija augmentacije	12

1. Uvod

U toku poslednje decenije smo svedoci sve boljih i naprednijih modela veštačke inteligencije, kako kod obrade slika, teksta, videa tako i kod audio podataka. Kao i kod drugih oblasti mašinskog učenja, performanse modela zavise dosta od kvaliteta i količine podataka nad kojima se trenira model. Prikupljanje velike količine kvalitetnih audio podataka (pogotovo anotiranih) je dosta skupo, vremenski zahtevno a u nekim slučajevima i nemoguće. Zbog ovoga primenjujemo augmentaciju podataka.

Augmentacija audio podataka, i uopšte bilo koja vrsta augmentacije podataka, predstavlja skup tehnika kojima se od postojećeg skupa podataka generišu dodatni podaci primenom različitih transformacija. Za razliku od augmentacije slika, koja je danas standardna praksa, augmentacija audio podataka ima dodatne izazove zbog vremenske prirode audio signala, kao i kompleksnosti percepcije zvuka kod ljudi.

Osnovni cilj augmentacije je da se poveća raznovrsnost i veličina trening skupa bez sakupljanja novih podataka, čime se model čini otpornijim na varijacije koje se mogu desiti tokom primene modela (šum npr). Jedan primer je prepoznavanje ljudskog govora. Ukoliko je model treniran na ljudskim glasovima snimljenim u studiju, postoji mogućnost da će performanse modela biti loše u realnim uslovima - na ulici, u kafiću, kod kuće itd.

U ovom radu ćemo prvenstveno obraditi šta je zvuk, kako se može opisati i predstaviti, kao i kakve različite tehnike augmentacije podataka. Razmotrićemo kako jednostavnije tako i kompleksnije transformacije, u različitim domenima, kada i kako treba primeniti date tehnike kao i njihove prednosti i nedostatke. Na kraju ćemo spomenuti kako možemo meriti efikasnost tehnika augmentacije koje će kasnije biti obrađene u praktičnom delu projekta.

2. Osnove audio signala

2.1 Digitalni audio signal

Zvuk je mehanički talas koji se prostire kroz neku sredinu kao rezultat vibracija. Kako bi se zvuk sačuvao na računaru on se zapisuje u digitalnom obliku, gde je predstavljen diskretizovanom verzijom kontinualnog zvučnog talasa. Proces digitalizacije se sastoji od semplovanja (sampling) i kvantizacije.

- **Sampling**

- Proces merenja amplitude zvučnog talasa u regularnim vremenskim intervalima. Frekvencija *sampling*-a određuje koliko puta u sekundi ćemo meriti amplitudu zvučnog signala. Po Nyquist-Shannon-ovoj teoremi semplovanja signala, potrebno je semplovati sa bar duplo manjom frekvencijom od izvorne frekvencije signala. U suprotnom dolazi do *aliasinga*




Figure 1: Semplovanje audio signala

Standardne frekvencije semplovanja (kHz)	Upotreba
8	telefonski govor
44.1	CD kvalitet
48	profesionalni audio
96 ili 192	high-res audio

Table 1: Broj vrednosti amplituda u zavisnosti od broja bitova

- **Kvantizacija**

- Kako su računari digitalni uređaji konačne preciznosti, potrebno je vrednosti amplitude signala mapirati na jednu od 2^n vrednosti, pri čemu n predstavlja broj bitova kojim možemo predstaviti vrednosti amplitude.

Broj bitova	Broj mogućih vrednosti amplitude
8	256
16	65,536 (CD)
24	16,777,216 (profesionalni audio)
32	4,294,967,296 (digitalna obrada signala)

Table 2: Broj vrednosti amplituda u zavisnosti od broja bitova

Audio signal se zatim predstavlja kao diskretan niz vrednosti $x[n]$. Kod mono signala to je jednodimenzionalni niz, dok stereo signal ima dva kanala.

2.2 Reprezentacije audio signala

Audio signali se mogu predstaviti i analizirati na više načina, pri čemu se uglavnom predstavljaju u vremenskom ili u frekventnom domenu.

- **Vremenski domen**

Najjednostavnija reprezentacija audio signala - prikaz amplitude signala kroz vreme.




Figure 2: Prikaz audio signala u vremenskom domenu

Prednosti	Nedostaci
Vremenske informacije su očuvane Nema gubitaka tokom konverzije Lako za razumevanje i prikaz	Nepogodno za analizu frekvencija Zahteva duže sekvence za neuronske mreže

Table 3: Prednosti i nedostaci prikaza audio signala u vremenskom domenu

- **Frekventni domen**

Furijevom transformacijom je moguće izvršiti dekompoziciju audio signala na njegove frekvencije. Analiza signala korišćenjem Furijeove transformacije je pogodna za slučajeve kada frekvencije signala ne variraju vremenom. U realnosti je ovo retkost, s obzirom da ljudski govor i muzika variraju vremenom, tj oni su aperiodični signali.

Zato umesto direktnog vršenja Furijeove transformacije nad signalom, možemo ulazni signal da podelimo na preklapajuće segmente a zatim nad njima vršiti FFT. Podelom audio signala na kratke preklapajuće segmente, a zatim primenom Furijeove transformacije dobijamo STFT - *Short Time Fourier Transform*.

Matematički STFT se može definisati kao

$$\text{STFT}\{x[n]\}(m, \omega) = \sum_{n=-\infty}^{\infty} x[n] w[n-m] e^{-j\omega n} \quad (1)$$

pri čemu je $x[n]$ ulazni signal u trenutku n , dok je w window funkcija i m vreme u okviru kog analiziramo frekvence.




Figure 3: Levo - Proces dobijanja STFT reprezentacije. Desno - STFT reprezentacija. X osa predstavlja vreme, Y osa frekvence a boja intenzitet.

Postoji više window funkcija, ispod je dat primer Hann-ove window funkcije

$$w[n] = \begin{cases} \frac{1}{2} \left(1 - \cos\left(\frac{2\pi n}{N-1}\right) \right), & 0 \leq n < N, \\ 0, & \text{u suprotnom.} \end{cases} \quad (2)$$

STFT reprezentacija međutim ne opisuje najbolje kako ljudsko uho percipira zvuk. Na osnovu istraživanja je zaključeno da ljudi najbolje registruju i razlikuju zvukove u rasponu frekvenci od 500 do 1000Hz, dok teško razlikuju više frekvence npr 1-1.5kHz. Upravo zato je osmišljena mel skala. Mel skala se dobija pretvaranjem linearnog spektrograma u logaritamski na sledeći način

$$m = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$$

pri čemu je m rezultujuća vrednost a f ulazna frekvencija.




Figure 4: Mel spektrogram

Mel spektrogram je pogotovo koristan kod zadataka prepoznavanja govora i muzike.

2.3 Izazovi u radu sa audio podacima

Rad sa audio podacima kod mašinskog učenja donosi nekoliko specifičnih izazova

- **Promenljivo trajanje zvučnih zapisa**

Za razliku od slika koje imaju fiksne dimenzije, audio snimci mogu biti proizvoljnog trajanja. Model mora biti u stanju da procesira signale različite dužine što može da uradi

- Korekcijom dužine snimka, skraćivanjem ili padd-ovanjem signala
- Korišćenjem arhitektura koje primaju ulaze različitih dužina (rekurentne mreže, transformeri)

- **Velika dimenzionalnost**

Audio sa frekvencijom smplovanja od 16kHz ima 16000 vrednosti u sekundi. Za snimak od 10 sekundi, to je 160000 vrednosti. Zbog toga se često koriste kompresovane reprezentacije.

- **Osetljivost na šum**

Zvukovi snimljeni u realnim uslovima često sadrže različite vrste šuma kao što su pozadinski šum, električni šum mikrofona, odjek prostorija, zvukove iz više različitih izvora koji se prepliću (govor više ljudi u isto vreme) itd.

- **Nedostatak label-ovanih podataka**

Kvalitetni, labelovani audio skupovi podataka su relativno mali i skupi. Problem je u tome što je za govor potrebno ručno izvršiti transkripciju sa preciznom vremenskom anotacijom, dok je za muziku potrebna kategorizacija žanrova, instrumenata, takta itd.

- **Varijabilnost govora**

Kod prepoznavanja govora mnogo faktora utiče na audio signal - jezik, akcenat, pol, emotivno stanje, brzina govora, artikulacija, pozadinski šum itd.

Baš zbog ovih izazova je augmentacija audio podataka ključna za treniranje modela koji će imati dobre performanse u realnim uslovima.




Figure 5: Nekoliko vrsta augmentacija audio signala

3. Osnove augmentacije audio signala

Augmentacija podataka je tehnika u mašinskom učenju koja uključuje kreiranje novih trening primera primenom transformacija na postojeće podatke. Metode augmentacije podataka su dizajnirane tako da uvedu dovoljno varijacije u skupu trening podataka tako da održe realističnost i semantički sadržaj ali i poboljšaju sposobnost modela da generalizuje.

Postoji više podela augmentacija audio podataka

1. Po domenu primen
 - **Augmentacije u vremenskom domenu**
Primenjuju se direktno na waveform audio zapisa
 - **Augmentacije u frekventnom domenu**
Primenjuju se na spectrogram audio zapisa
 - **Augmentacije u feature prostoru**
Primenjuju se na ekstrakovnim feature-ima
2. Po složenosti
 - **Jednostavne transformacije**
Dodavanje šuma, promena pitch-a
 - **Kompozitne transformacije**
Nastaju kombinaciju više jednostavnih transformacija
 - **Naučene transformacije**
Transformacije primenom treniranih modela kao što su GAN ili varijacioni auto-encodери
3. Po determinističnosti
 - **Determinističke**
Ista transformacija daje iste rezultate
 - **Stohastičke**
Uvode nasumičnost tokom transformacija

Ciljevi augmentacije podataka su

- **Povećanje veličine trening skupa**
Osnovni cilj je kreiranje većeg i raznovrsnijeg trening skupa bez skupljanja novih podataka. Duboke neuronske mreže, posebno konvolucione mreže i transformeri, zahtevaju velike količine podataka da bi efikasno naučile reprezentacije podataka.
- **Regularizacija i smanjenje overfitting-a**
Uvođenjem varijacije u trening podatke, sprečavamo model da “zapamti” specifične detalje trening skupa. Umesto toga, model mora naučiti robusnije feature-e koji generalizuju na varijacije.
- **Simulacija realnih varijacija**
U produkciji, model će često morati da koristi zvukove koji se razlikuju od trening podataka po kvalitetu snimanja, pozadinskom šumu, akustici prostorije, karakteristikama govornika, itd. Augmentacijom možemo da simuliramo ove varijacije tokom treninga, čineći model otpornijim na realne uslove korišćenja.
- **Balansiranje skupa podataka**
U mnogim scenarijima, dostupni podaci nisu ravnomerno distribuirani kroz klase. Na primer, u skupu podataka za klasifikaciju emocija govornika, normalan govor može biti mnogo češći od ljutitog ili tužnog govora. Selektivnom augmentacijom manje zastupljenih klasa možemo poboljšati balans skupa podataka.

4. Augmentacija audio signala u vremenskom domenu

4.1 Time Stretching

4.2 Pitch Shifting

4.3 Dodavanje nasumičnog šuma

4.4 Time Shifting

4.5 Random Gain

5. Augmentacija audio signala u frekventnom domenu

6. Napredne tehnike augmentacije

7. Evaluacija augmentacije